

Otimização da Compressão *Wavelet* de Sinais como Problema da Mochila Binária

Laura Armiliato Sangalli¹ Marco Antonio de Castro Barbosa²

¹Acadêmica de Engenharia de Computação – Universidade Tecnológica Federal do Paraná (UTFPR)

85.503-390 – Pato Branco – PR – Brasil

²Departamento de Informática – Universidade Tecnológica Federal do Paraná (UTFPR)

85.503-390 – Pato Branco – PR – Brasil

Abstract. *Signal compression based on the Discrete Wavelet Transform is an effective approach for reducing storage requirements while preserving the essential characteristics of the original signal. However, selecting the most relevant Wavelet coefficients under storage constraints can be formulated as a binary knapsack optimization problem, which belongs to the NP-hard class. This work evaluates three optimization approaches for Wavelet coefficient selection: a greedy algorithm, a Variable Neighborhood Descent (VND) heuristic, and the Simulated Annealing metaheuristic. Experiments were conducted using synthetic signals with 1,000 samples and three compression levels, corresponding to the storage of 50, 250, and 500 Wavelet coefficients. The algorithms were compared using the Root Mean Square Error (RMSE) between the original and reconstructed signals, as well as their execution time. The obtained results highlight the strengths and limitations of each optimization strategy regarding reconstruction quality and computational cost. .*

Resumo. *A compressão de sinais por Transformada Wavelet Discreta constitui uma alternativa eficiente para reduzir a quantidade de dados armazenados, preservando as principais características do sinal original. Entretanto, a seleção dos coeficientes Wavelet mais relevantes sob restrições de armazenamento pode ser modelada como um problema de otimização combinatória do tipo mochila binária, pertencente à classe NP-difícil. Neste trabalho, são avaliados três métodos para a seleção de coeficientes wavelet: um algoritmo guloso, uma heurística de refinamento por Descida em Vizinhança Variável (DVV) e a meta-heurística Simulated Annealing. Os experimentos foram realizados com a utilização de sinais sintéticos com 1000 amostras e diferentes níveis de compressão, correspondentes ao armazenamento de 50, 250 e 500 coeficientes Wavelet. O desempenho dos algoritmos foi avaliado por meio da Raiz do Erro Quadrático Médio (RMSE) entre o sinal original e o sinal reconstruído, bem como pelo tempo de execução. Os resultados obtidos evidenciam as vantagens e limitações de cada abordagem ao comparar a qualidade das soluções e o custo computacional associado à compressão.*

1. Introdução

A compressão de dados é uma ferramenta que possibilita o desenvolvimento de diversas aplicações com limitações de armazenamento. Reduzir a quantidade de dados

armazenados, ao mesmo tempo que suas características são mantidas é um desafio inerente à áreas como Internet das Coisas e Sistemas Embarcados que, muitas vezes, são utilizadas em situações com recursos limitados [Correa et al. 2022]. Entretanto, um desafio relacionado à compressão é minimizar a informação perdida, de forma que o seu resultado seja o mais semelhante possível ao que seria obtido com o conjunto de dados sem estar comprimido. Com o propósito de realizar tal seleção de maneira coerente, diversas aplicações de compressão de dados foram desenvolvidas ao longo das últimas décadas. Algumas dessas ferramentas utilizam transformadas matemáticas, e um caso comum entre elas é a utilização das transformadas *Wavelet*, como ocorre na compressão de imagens JPG2000 [A. N. Skodras¹ and Ebrahimi 2001] e em trabalhos recentes de compressão de sinais de eletrocardiograma [Pal et al. 2024] [Melek and Khattab 2021].

Em aspectos técnicos da compressão de dados, um dos seus principais problemas é determinar quais dados manter e como armazená-los. No âmbito da transformada wavelet, a seleção dos coeficientes em situações de armazenamento limitado é um problema que possui diversas soluções. Algumas delas reconstroem o sinal com bastante precisão, outras, degradam sua formação de maneira elevada. Analisar todas as combinações possíveis de coeficientes que produzem tais soluções seria uma tarefa de busca exaustiva e acarretaria um elevado custo computacional, embora proporcione a certeza do encontro da solução ótima. Além disso, quanto maior o conjunto de dados a serem comprimidos, maior se torna o volume de processos computacionais a serem realizados.

Em virtude desses apontamentos, torna-se visível que a compressão de dados por transformada *Wavelet* é um problema não-polinomial, mais especificamente, uma variante do problema da mochila, pertencente à classe NP-difícil [Dantzig 1957]. Isso pode ser afirmado porque é possível transcrever a compressão de tal modo.

Do problema original, considera-se uma mochila com capacidade C e um conjunto de n elementos, cada qual com um peso p e um valor v . Deseja-se completar a capacidade da mochila de modo que o valor total armazenado nela seja o máximo em meio às combinações possíveis com os n elementos, ou seja, busca-se encontrar a solução ótima por meio de uma maximização do valor armazenado [Dantzig 1957]. Tal composição adequa-se às características da compressão de sinais wavelet, uma vez que essa atividade apresenta um viés de otimização combinatória, com vistas a armazenar o máximo de informação possível e maximizar um rendimento comum relacionado, característica do problema clássico da mochila.

De acordo com [Vetterli and Kovacevic 1995], a qualidade da compressão de um sinal com transformada *Wavelet* está diretamente relacionada à energia dos coeficientes preservados durante o processo de reconstrução. Em outras palavras, maiores valores absolutos de coeficientes armazenados tendem a elevar a fidelidade do sinal resultante da compressão. Todavia, como deseja-se limitar a quantidade de dados armazenados e transmitidos, torna-se necessário selecionar apenas os coeficientes mais significativos. Esse comportamento decorre do fato de que a transformada *Wavelet* concentra grande parte da energia do sinal em alguns coeficientes de maior magnitude, permitindo que coeficientes de menor relevância sejam descartados com impacto reduzido na qualidade final do sinal.

Esse trabalho tem como objetivo analisar o resultado de três diferentes métodos

de otimização para a seleção de coeficientes com a transformada *Wavelet* discreta *db7* [Daubechies 1992]. São eles o método guloso, a heurística de descida em vizinhança variável (DVV) e a meta-heurística *Simulated Annealing*(SA). O desempenho de cada uma das compressões será avaliado pela raiz do erro quadrático médio (RSME) do sinal comprimido resultante em relação ao sinal original. Como resultado, busca-se investigar a eficácia das heurísticas aplicadas nos métodos de seleção de coeficientes *Wavelet* sob restrições de armazenamento.

1.1. Trabalhos relacionados

Na atualidade, diversos trabalhos sobre otimização da compressão de dados com transformada *Wavelet* tem sido publicados. Como exemplo, [Pal et al. 2024] propõe uma técnica de compressão para sinais de eletrocardiograma bidimensionais, a qual utiliza a transformada *Wavelet* discreta (DWT) unidimensional associada ao algoritmo de Otimização por Enxame de Partículas (PSO), para selecionar os níveis ideais de decomposição e parâmetros de quantização. No mesmo sentido, o artigo [Shirai et al. 2024] apresenta um sistema para detecção de falhas em máquinas que utiliza a DWT para comprimir sinais sonoros industriais, garantindo a redução do volume de dados sem comprometer a integridade de sons anômalos.

Paralelamente, diversos artigos sobre otimização com problema da mochila binária têm sido divulgados. De acordo com dados de [Feng et al. 2026], desde o ano 2020, mais de 240 artigos relacionados às diferentes variações de problema da mochila foram publicados, sendo a variação binária predominante em número de publicações entre 2014 e 2025. Um exemplo das publicações mais recentes é o artigo de [Sakib et al. 2025], que efetua uma análise comparativa do desempenho de heurísticas de refinamento clássicas aplicadas ao problema da mochila binária. Outro trabalho é o de [Luo et al. 2022], que introduz uma nova heurística, a qual vale-se da estratégia gulosa conjuntamente a um modelo de nuvens, para lidar com incertezas na escolha dos itens mais promissores em cada uma das etapas da busca da solução.

2. Referencial Teórico

Para o entendimento da metodologia aplicada, é necessário o conhecimento de alguns conceitos. Uma das fundamentações básicas a serem descritas é a Transformada *Wavelet* Discreta (DWT). É necessário compreender como ocorre a obtenção de seus coeficientes, bem como a sua organização em bandas. Essas contextualizações serão apresentadas nas subseções a seguir.

De modo a otimizar a seleção de tais coeficientes, foram utilizados três diferentes métodos de otimização, nomeados também como heurísticas. Iniciou-se o desenvolvimento com a aplicação do método guloso [Cormen et al. 2009], com vistas a obter uma solução ótima local inicial. Em seguida, buscou-se uma heurística de refinamento para a solução resultante do método guloso. Após uma seleção, optou-se pelo método da descida em vizinhança variável, proposto por [Hansen et al. 2010]. Por fim, a heurística de construção, nomeada também de meta-heurística, ainda está a ser definida.

A seguir, serão contextualizados os conceitos aplicados durante o processo de otimização.

2.1. Compressão de sinais

A compressão consiste em reduzir a quantidade de dados necessária para representar um sinal de modo a limitar o espaço de armazenamento ocupado por ele, mantendo as suas características originais [Salomon 2004, Sayood 2017]. Existem dois tipos de compressão, a sem perdas, que é a conversão em que a reconstituição do sinal comprimido é idêntica ao original e a com perdas, na qual admite-se uma degradação moderada da informação de modo a reduzir a quantidade de dados armazenados [Sayood 2017].

Em processamentos de sinais que utilizam transformadas wavelet, é comum utilizar a compressão com perdas, pois muitos dos coeficientes obtidos na etapa de decomposição têm valores próximos de zero [Mallat 1999], ou seja, pouca relevância para a reconstituição do sinal. Além disso, a seleção desses coeficientes é um ponto relevante à aplicação do problema da mochila binária em tal contexto.

2.2. Transformada wavelet

A Transformada *Wavelet* realiza uma análise de tempo-frequência [Mallat 1999, Daubechies 1992] do sinal. A fórmula geral para a Transformada *Wavelet* contínua é dada por:

$$W(a, b) = \frac{1}{\sqrt{|a|}} \int_{-\infty}^{\infty} x(t) \psi^* \left(\frac{t - b}{a} \right) dt$$

[Daubechies 1992, Mallat 1999], em que $x(t)$ é a função original, $\psi(t)$ é a função *Wavelet* mãe, a é o parâmetro de escala e b é a posição no tempo (t) de acordo com a escala utilizada.

No presente trabalho, foram analisados sinais no tempo discreto. Para aplicações discretas da função, o método costuma ser um pouco diferente. Normalmente, utiliza-se um banco de filtros *Wavelet* de acordo com a família *Wavelet* escolhida [Vetterli and Kovacevic 1995]. Nesse contexto, o sinal é processado e agrupado em diferentes bandas por meio de sucessivas filtragens passa-alta e passa-baixa, seguidas por etapas de subamostragem. Os elementos da banda com as frequências mais baixas do sinal são conhecidos como coeficientes de aproximação, enquanto os pertencentes as demais bandas, caracterizadas por frequências mais altas, são nomeados coeficientes de detalhe [Mallat 1989].

A decomposição de um sinal por meio da transformada *Wavelet* pode ser realizada em múltiplos níveis, permitindo a análise do sinal em diferentes escalas de resolução [Vetterli and Kovacevic 1995]. Diferentemente da Transformada de Fourier [Oppenheim and Schaffer 1999], que representa apenas o conteúdo em frequência e não preserva a localização temporal das componentes do sinal, a transformada *Wavelet* efetua uma análise em tempo-frequência. Dessa forma, cada coeficiente obtido está associado tanto a uma faixa de frequência quanto a uma determinada posição temporal do sinal original. Essa característica possibilita investigar variações locais do sinal em diferentes níveis de detalhe.

Existem diversas famílias de funções wavelet, cada uma com combinações singulares de suporte, regularidade e simetria [Daubechies 1992, Vetterli and Kovacevic 1995].

Neste trabalho, foi adotada a db7, uma *Wavelet* da família Daubechies [Daubechies 1992], frequentemente utilizada em aplicações de análise e compressão de sinais [Pal et al. 2024].

2.3. Problema da mochila binária

A primeira definição do problema np-difícil [Garey and Johnson 1979] da mochila binária foi descrita por [Dantzig 1957]. Dado um conjunto de n elementos, cada qual com peso p_i valor v_i , o objetivo é encontrar o máximo valor total T que tenha possibilidade de ser alocado, em termos de peso, dentro da capacidade C da mochila. Em outras palavras, pode-se definir esse problema matematicamente pela equação de conformidade com a capacidade

$$\sum_{i=1}^n p_i x_i \leq C$$

que satisfaça o valor total acumulado

$$T = \sum_{i=1}^n v_i x_i$$

Assim, busca-se maximizar o valor total armazenado na mochila sem exceder sua capacidade máxima.

O problema de compressão analisado pode ser formulado como uma variante binária do problema da mochila, uma vez que cada coeficiente possui uma variável de decisão associada, indicando sua seleção ou descarte [Feng et al. 2026]. Dessa forma, a escolha de um coeficiente não implica necessariamente a seleção de toda a banda à qual ele pertence, diferentemente do que ocorre no problema da mochila com união de conjuntos.

Problemas binários da mochila com uma quantidade de elementos pequena a ser alocada podem ser resolvidos com algoritmos clássicos de ordem quadrática. Tanto o método *Branch-and-Bound* [Martello and Toth 1990, Pisinger 1995] quanto a Programação Dinâmica [Bellman 1957, Martello and Toth 1990] encontram facilmente a solução ótima para o Problema da Mochila Binária, entretanto, acarretam grande custo computacional. Para situações com mais de mil itens, caso facilmente atingido para a compressão de dados numéricos, tais soluções tornam-se pouco viáveis.

2.4. Algoritmo guloso

Também conhecido como Método Greedy, o Algoritmo Guloso é uma estratégia prática para resolver problemas de otimização [Cormen et al. 2009]. Seu desenvolvimento consiste em buscar sempre o valor ótimo imediato, ou semelhante, para cada etapa percorrida, sem verificação posterior da eficácia da escolha. A composição desses resultados pode levar a uma solução ótima local, entretanto, em algumas situações, pode atingir também o resultado ótimo global. Apesar de sua eficácia temporal, como seu objetivo é proporcionar saídas rápidas e de baixo custo computacional, ele não realiza validações acuradas sobre a efetividade de suas respostas e, em alguns casos, pode proporcionar resultados distantes da verdadeira maximização.

Nas aplicações da atualidade, o algoritmo guloso costuma ser utilizado como estratégia para problemas que não necessariamente urgem a solução ótima, bem como

para proporcionar resultados iniciais e de mapeamento em problemas de otimização [Cormen et al. 2009].

2.5. Descida em vizinhança variável

A heurística de descida em vizinhança variável (DVV) foi proposta inicialmente por [Hansen et al. 2010], como uma variação do método de busca em vizinhança variável. De acordo com os autores, essa heurística pode ser combinada com outros métodos ou aplicada sozinha. Além disso, seus critérios de parada podem ser diversos, de acordo com a implementação. Seu propósito é explorar conjuntos de vizinhanças diferentes em meio ao espaço de busca, de modo a evitar a concentração em ótimos locais e garantir uma maior exploração das possíveis soluções. Opondo-se a métodos que exploram um único conjunto de vizinhanças, a DVV explora um espaço de soluções que costuma ser mais abrangente, o que possibilita taxas de melhora progressivas.

Inicialmente, denota-se um conjunto de vizinhanças N , as quais serão avaliadas ao longo da execução do algoritmo. A próxima etapa é a definição de uma solução inicial, por exemplo, a obtida pelo método guloso. Em seguida, designa-se um critério de parada para o algoritmo como, por exemplo, um número máximo de iterações. Após essa seleção, as vizinhanças são exploradas de forma sistemática, com vistas a encontrar o melhor resultado vizinho subsequente.

2.6. Meta-heurística

A meta-heurística adotada neste trabalho foi o *Simulated Annealing* [Kirkpatrick et al. 1983]. O método inspira-se no processo físico de recozimento de metais, no qual um material é inicialmente aquecido a elevadas temperaturas e posteriormente resfriado de forma gradual, permitindo que sua estrutura atinja estados de menor energia.

No contexto de otimização combinatória, a energia corresponde ao valor da função objetivo. O algoritmo inicia a partir de uma solução inicial e, a cada iteração, gera uma solução vizinha por meio de pequenas modificações na solução corrente. Caso a solução obtida apresente melhora na função objetivo, ela é imediatamente aceita. Entretanto, diferentemente de heurísticas puramente determinísticas, o *Simulated Annealing* também admite a aceitação de soluções de qualidade inferior com uma probabilidade dependente da temperatura do sistema.

Essa probabilidade é definida por

$$P = e^{\frac{-\Delta}{T}}$$

em que Δ representa a diferença entre o custo da solução candidata e da solução atual, enquanto T corresponde à temperatura corrente do algoritmo. À medida que o processo evolui, a temperatura é reduzida gradualmente segundo um fator de resfriamento, o que diminui também a probabilidade de aceitar soluções inferiores. Esse mecanismo possibilita escapar de ótimos locais durante as primeiras etapas da busca, tornando o método particularmente adequado para problemas NP-difíceis, como o problema da mochila binária.

3. Metodologia

A metodologia empregada neste trabalho foi dividida em três etapas principais. Inicialmente realizou-se a decomposição dos sinais utilizando a DWT da família Daubechies db7. Em seguida, foi aplicada uma heurística construtiva baseada no método guloso para selecionar os coeficientes considerados mais relevantes para a reconstrução do sinal sob uma restrição de armazenamento. Posteriormente, essa solução inicial foi refinada por meio de heurísticas de busca local e de uma meta-heurística.

3.1. Organização dos experimentos

Todos os experimentos foram realizados utilizando sinais compostos por 1000 amostras. Após a decomposição por meio da DWT utilizando a *Wavelet* Daubechies db7, foram considerados três níveis de compressão, correspondentes ao armazenamento de 50, 250 e 500 coeficientes *Wavelet*. Esses valores foram escolhidos com o objetivo de avaliar o comportamento dos algoritmos sob diferentes restrições de armazenamento, permitindo analisar desde cenários de alta compressão até situações com maior preservação da informação.

Em todos os experimentos, o desempenho dos métodos foi avaliado utilizando a Raiz do Erro Quadrático Médio (RMSE) entre o sinal original e o sinal reconstruído. Além da qualidade da reconstrução, também foi analisado o tempo de execução de cada algoritmo, avaliação que permitiu comparar simultaneamente eficiência computacional e qualidade das soluções obtidas.

3.2. Otimização por método guloso

O algoritmo guloso foi empregado como estratégia para obtenção de uma solução inicial de baixo custo computacional. Inicialmente, realizou-se a decomposição do sinal por meio da Transformada *Wavelet* Discreta. Em seguida, todos os coeficientes foram ordenados segundo seus valores absolutos, uma vez que coeficientes de maior magnitude concentram maior parcela da energia do sinal.

Respeitando a quantidade máxima de coeficientes permitida para armazenamento, foram preservados apenas os coeficientes de maior magnitude, enquanto os demais receberam valor nulo. Após essa etapa, efetuou-se a reconstrução do sinal utilizando a transformada *Wavelet* inversa, sendo calculado o RMSE correspondente.

Essa abordagem produz rapidamente uma solução viável para o problema, servindo também como ponto de partida para os métodos de refinamento empregados posteriormente.

3.3. Otimização por Descida em Vizinhança Variável

Após a obtenção da solução inicial pelo método guloso, foi aplicada uma heurística de Descida em Vizinhança Variável (DVV) com o objetivo de melhorar a qualidade da solução encontrada.

A vizinhança foi construída realizando trocas entre coeficientes atualmente selecionados e coeficientes inicialmente descartados, mantendo constante a quantidade total de coeficientes armazenados. A cada iteração, uma nova solução candidata era gerada e comparada com a solução corrente por meio do RMSE do sinal reconstruído.

Sempre que uma solução apresentava redução do erro de reconstrução, ela substituí a solução corrente. O procedimento era repetido até que nenhuma melhoria adicional fosse encontrada dentro das vizinhanças consideradas, caracterizando um ótimo local para a estrutura de vizinhança adotada.

3.4. Otimização por meta-heurística

Como estratégia adicional de refinamento, foi empregado o algoritmo *Simulated Annealing*. A solução inicial utilizada pelo algoritmo correspondeu ao resultado obtido pelo método guloso.

Em cada iteração, uma nova solução candidata foi construída mediante a substituição aleatória de um conjunto de coeficientes atualmente selecionados por coeficientes previamente descartados, preservando a restrição de armazenamento imposta ao problema. Após a reconstrução do sinal correspondente, calculou-se o RMSE em relação ao sinal original.

Caso o RMSE da nova solução fosse inferior ao da solução corrente, ela era imediatamente aceita. Caso contrário, sua aceitação ocorria segundo uma probabilidade dependente da temperatura do algoritmo. Inicialmente, temperaturas elevadas permitiam maior exploração do espaço de soluções. Com o resfriamento progressivo do sistema, o comportamento do algoritmo tornava-se gradualmente mais conservador, concentrando-se na exploração das regiões promissoras do espaço de busca.

Ao término do processo de resfriamento, era retornada a melhor solução encontrada durante toda a execução.

4. Resultados Parciais

A Tabela 1 apresenta os resultados obtidos para sinais com 1000 amostras submetidos aos três níveis de compressão considerados (50, 250 e 500 coeficientes *Wavelet* armazenados). Observa-se que o desempenho dos algoritmos varia de acordo com a complexidade do sinal analisado e com a quantidade de coeficientes preservados durante o processo de compressão. De maneira geral, o aumento do número de coeficientes armazenados reduz o erro de reconstrução (RMSE), uma vez que uma parcela maior da informação original é mantida. Além disso, verifica-se que as heurísticas de refinamento tendem a produzir soluções de melhor qualidade em comparação ao método guloso, embora isso implique um aumento no tempo de processamento. O *Simulated Annealing* apresentou comportamento semelhante ao da heurística de refinamento em termos de qualidade da solução, porém com um custo computacional significativamente superior, consequência da exploração do espaço de busca e do elevado número de iterações necessárias durante o processo de resfriamento.

As Figuras 1, 2 e 3 a seguir exibem o comportamento da reconstrução de sinais decompostos pela transformada *Wavelet* e comprimidos para análise do problema da mochila. A Figura 1 representa o sinal $x(a) = \sin(5a)$, a Figura 2 mostra o sinal $x(a) = 4\sin(a) + 2.3\sin(30a)$ e a Figura 3 exibe o sinal $x(a) = \sin(10a) + r$, sendo r um ruído. Para cada uma das Figuras, as linhas de cima para baixo exibem o resultado da aplicação do Algoritmo Guloso, da Descida em Vizinhança Variável e do *Simulated Annealing*, respectivamente. Além disso, da direita para a esquerda, os sinais foram reconstruídos a partir dos respectivos níveis de compressão 50, 250 e 500.

Table 1. Comparação entre os métodos de otimização para diferentes sinais de entrada.

Sinal de Entrada	Solução Esperada	Vetor	Coef.	Método Guloso		VND		Simulated Annealing	
				RMSE	Tempo (s)	RMSE	Tempo (s)	RMSE	Tempo (s)
$x(a) = a$	RMSE = 0	1000	50	0,01261	0,0165	0,01261	0,0021	0,01261	83,9773
		1000	250	0,01261	0,0167	0,01261	0,0022	0,01261	77,8648
		1000	500	0,01261	0,0156	0,01261	0,0021	0,01261	70,0782
$x(a) = a^2 - 10a + 15$	RMSE = 0	1000	50	0,17283	0,0155	0,17283	0,0020	0,17283	85,0070
		1000	250	0,17283	0,0159	0,17283	0,0018	0,17283	73,2990
		1000	500	0,17283	0,0151	0,17283	0,0018	0,17283	73,2305
$x(a) = \sin(5a)$	RMSE = 0	1000	50	0,09385	0,0132	0,09338	0,0889	0,00672	70,4467
		1000	250	0,00935	0,0157	0,00672	0,3830	0,00672	74,4029
		1000	500	0,00935	0,0155	0,00672	0,3739	0,00672	73,3531
$x(a) = 4 \sin(a) + 2,3 \sin(30a)$	RMSE = 0	1000	50	1,52304	0,0114	1,51339	0,1191	0,11188	71,8373
		1000	250	0,11672	0,0117	0,11188	0,5611	0,11188	73,5497
		1000	500	0,11672	0,0112	0,11188	0,5147	0,11188	70,8390
$x(a) = \sin(10a) + \text{rand}$	RMSE = 0	1000	50	0,73629	0,0114	0,71323	0,0378	0,23637	71,1168
		1000	250	0,23637	0,0139	0,23637	4,8805	0,23637	71,7516
		1000	500	0,23028	0,0135	0,23637	3,5788	0,23637	72,0076
$x(a) = \sin(3a) \cdot \text{rand}$	RMSE = 0	1000	50	0,19996	0,0099	0,19971	0,0406	0,08389	70,9208
		1000	250	0,13622	0,0114	0,13514	6,4250	0,08389	72,9229
		1000	500	0,08049	0,0112	0,07990	15,9110	0,08389	71,5888
$x(a) = \log(a^2)$	RMSE = 0	1000	50	0,01287	-0,98713	0,01287	0,2230	0,01287	72,2980
		1000	250	0,01287	-0,98713	0,01287	0,2205	0,01287	70,7843
		1000	500	0,01287	-0,98713	0,01287	0,2369	0,01287	74,2785




Figure 1. Gráficos de reconstrução do sinal $x(a) = \sin(5a)$




Figure 2. Gráficos de reconstrução do sinal $x(a) = 4 \sin(a) + 2.3 \sin(30a)$




Figure 3. Gráficos de reconstrução do sinal $x(a) = \sin(10a) + r$

Da avaliação de tais dados, bem como do processo de implementação dos algoritmos, foi possível observar as considerações apresentadas a seguir.

4.1. Método Guloso

- Para sinais simples, como funções afim, quadrática e logarítmica, mesmo com poucos coeficientes armazenados, a reconstrução apresentou perda mínima de informação;
- Para senoides com frequências mais elevadas, o sinal reconstruído apresentou maior degradação, mesmo com o aumento da quantidade de coeficientes mantidos;
- Em sinais ruidosos ou com variações bruscas, pequenos detalhes não foram preservados fielmente;
- A seleção por método guloso impactou diretamente a qualidade do sinal reconstruído ao longo do tempo, principalmente em sinais mais complexos, nos quais houve maior perda de informação em regiões intermediárias e finais quando poucos coeficientes foram armazenados.

4.2. Heurística de Refinamento por Descida em Vizinhança Variável

- Para funções afim, quadrática e logarítmica, que já apresentavam erro mínimo e constante com o método guloso, a aplicação da DVV manteve os mesmos valores de RMSE, alterando apenas o tempo de execução;
- Para a maior parte das demais funções analisadas, houve redução do RMSE em relação ao método guloso, embora não seja possível afirmar se os valores obtidos correspondem à solução ótima global;
- O tempo de execução aumentou em todos os casos com a aplicação da DVV, comportamento esperado devido à etapa adicional de refinamento executada após a solução inicial obtida pelo método guloso.

4.2.1. *Simulated Annealing*

- Considerando os casos de testes analisados para os outros dois métodos, em apenas um dos casos, com capacidade igual a 250, obteve-se uma melhoria em relação à já obtida no refinamento por Descida em Vizinhança Variável.
- O tempo obtido na execução do *Simulated Annealing* foi o maior entre os três métodos implementados para todos os casos de teste. Ele superou os 70 segundos em todas as implementações realizadas.
- Não é possível saber se os resultados obtidos, com ou sem melhoria identificada, são as soluções ótimas para os problemas.

4.3. Conclusão

Os resultados parciais obtidos demonstram que a modelagem da seleção de coeficientes *Wavelet* como um problema da mochila binária constitui uma abordagem adequada para problemas de compressão de sinais sob restrições de armazenamento. O método guloso apresentou desempenho computacional promissor, pois produziu soluções iniciais em tempos reduzidos, embora apresente limitações para sinais com maior complexidade espectral.

A aplicação da heurística de Descida em Vizinhança Variável permitiu reduzir o erro de reconstrução na maior parte dos sinais analisados, situação que evidencia que o refinamento local é capaz de superar parte das limitações inerentes ao algoritmo guloso.

A meta-heurística *Simulated Annealing* também apresentou desempenho satisfatório no refinamento da seleção dos coeficientes *wavelet*, reduzindo o erro de reconstrução em comparação com o método guloso. Contudo, os resultados obtidos foram semelhantes aos alcançados pela Descida em Vizinhança Variável, enquanto o tempo de processamento foi significativamente maior, em razão da natureza pseudoaleatória do algoritmo e do elevado número de iterações executadas durante o processo de otimização. Assim, os experimentos indicam que a escolha do método mais adequado deve considerar o equilíbrio entre a qualidade da reconstrução do sinal e o custo computacional associado ao processo de compressão.

References

- A. N. Skodras¹, C. A. C. and Ebrahimi, T. (2001). Jpeg2000: The upcoming still image compression standard. *Pattern recognition letters*, 22(12):1337–1345.
- Bellman, R. (1957). *Dynamic Programming*. Princeton University Press.
- Cormen, T. H., Leiserson, C. E., Rivest, R. L., and Stein, C. (2009). *Introduction to Algorithms*. MIT Press, 3 edition.
- Correa, J. D. A., Pinto, A. S. R., and Montez, C. (2022). Lossy data compression for iot sensors: A review. *Internet of Things*, 19:100516.
- Dantzig, G. B. (1957). Discrete-variable extremum problems. *Operations research*, 5(2):266–288.
- Daubechies, I. (1992). *Ten Lectures on Wavelets*. SIAM.
- Feng, Y., Hu, T., Chen, X.-A., and Wang, G.-G. (2026). Recent advances in knapsack problem: A comprehensive review of models, algorithms, and applications. *Neuro-computing*, 666:132135.
- Garey, M. R. and Johnson, D. S. (1979). *Computers and Intractability: A Guide to the Theory of NP-Completeness*. Freeman.
- Hansen, P., Mladenović, N., and Moreno Pérez, J. A. (2010). Variable neighbourhood search: methods and applications. *Annals of Operations Research*, 175:367–407.
- Kirkpatrick, S., Gelatt, C. D., and Vecchi, M. P. (1983). Optimization by simulated annealing. *Science*, 220(4598):671–680.
- Luo, Z., Guo, X., Wen, B., and Cao, J. (2022). An evolution algorithm based on cloud model for 0-1 knapsack problem. pages 147–150.
- Mallat, S. (1989). A theory for multiresolution signal decomposition: the wavelet representation. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 11(7):674–693.
- Mallat, S. (1999). *A Wavelet Tour of Signal Processing*. Academic Press.

- Martello, S. and Toth, P. (1990). *Knapsack Problems: Algorithms and Computer Implementations*. John Wiley & Sons.
- Melek, M. and Khattab, A. (2021). Ecg compression using wavelet-based compressed sensing with prior support information. *Biomedical Signal Processing and Control*, 68:102786.
- Oppenheim, A. V. and Schaffer, R. W. (1999). *Discrete-Time Signal Processing*. Prentice Hall.
- Pal, H. S., Kumar, A., Vishwakarma, A., Singh, G. K., and Lee, H.-N. (2024). A new automated compression technique for 2d electrocardiogram signals using discrete wavelet transform. *Engineering Applications of Artificial Intelligence*, 133:108123.
- Pisinger, D. (1995). An expanding-core algorithm for the exact 0–1 knapsack problem. *European Journal of Operational Research*, 87(1):175–187.
- Sakib, F. F., Joy, J. S., Juel, S. I., and Hasan, M. M. (2025). Applying heuristic algorithms for solving the 0–1 knapsack problem: An experimental analysis. pages 356–360.
- Salomon, D. (2004). *Data Compression: The Complete Reference*. Springer.
- Sayood, K. (2017). *Introduction to Data Compression*. Morgan Kaufmann.
- Shirai, M., Yamamoto, S., Matsumoto, T., and Sode, M. (2024). Audio signal compression in a surround environment using wavelet transform. In *2024 17th International Conference on Sensing Technology (ICST)*, pages 1–6.
- Vetterli, M. and Kovacevic, J. (1995). *Wavelets and subband coding*, volume 87. Prentice Hall PTR Englewood Cliffs, NJ.